ỨNG DỤNG MÔ HÌNH NGÔN NGỮ, MÔ HÌNH NGÔN NGỮ LỚN THỰC HIỆN TÓM TẮT VĂN BẢN THEO HAI PHƯƠNG PHÁP EXTRACTIVE VÀ ABSTRACTIVE

GIỚI THIỆU BÀI TOÁN

Ngày nay, có rất nhiều các loại văn bản tiếng Việt.

- Báo điện tử, mạng xã hội, báo cáo, tài liệu kỹ thuật, văn bản hành chính...
- Người dùng không đủ thời gian để đọc hết.
- Doanh nghiệp cần tự động hóa việc lọc, tổng hợp thông tin.

Nhu cầu tạo ra bản tóm tắt ngắn gọn, mạch lạc, giúp nắm bắt ý chính!!

GIỚI THIỆU BÀI TOÁN

Ngày nay, có rất nhiều các loại văn bản tiếng Việt.

- Báo điện tử, mạng xã hội, báo cáo, tài liệu kỹ thuật, văn bản hành chính...
- Người dùng không đủ thời gian để đọc hết.
- Doanh nghiệp cần tự động hóa việc lọc, tổng hợp thông tin.

Nhu cầu tạo ra bản tóm tắt ngắn gọn, mạch lạc, giúp nắm bắt ý chính!!

Cần các phương pháp tóm tắt văn bản tự động và tin cậy cho tiếng Việt.

GIỚI THIỆU BÀI TOÁN

Sự ra đời của mô hình dựa trên Transformer đã thay đổi hoàn toàn NLP..

Mở ra khả năng xây dựng hệ thống tóm tắt tiếng Việt với chất lượng gần mức con người.

Encoder-only	Decoder-only	Encoder-Decoder
BERT, PhoBERT, RoBERTa	**T5, ViT5, mT5**	**LLaMA, Mistral, GPT-style**
Mạnh ở hiểu ngữ nghĩa, phân loại, trích xuất.	Phù hợp với sinh văn bản.	Có khả năng zero-shot, few-shot trên nhiều tác vụ.

GIỚI THIỆU BÀI TOÁN

Có hai hướng tóm tắt văn bản

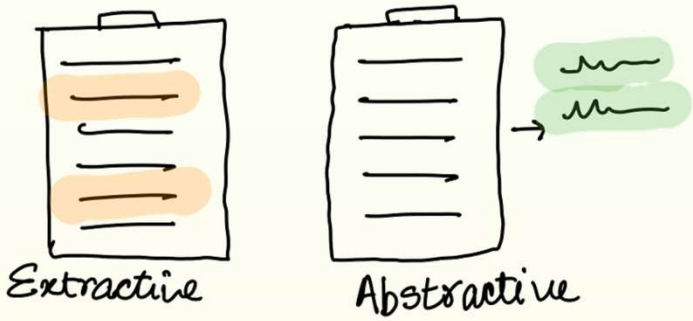

Extractive summarization

Tóm tắt trích xuất

Xác định và trích xuất các câu hoặc cụm từ quan trọng từ văn bản cần tóm tắt.

- Ưu: Dễ triển khai, ít lỗi ngữ pháp, đảm bảo tính chính xác của nội dung.
- Nhược: Bản tóm tắt có thể thiếu mạch lạc, không hiểu ngữ nghĩa sâu trong văn bản.

Abstractive summarization

Tóm tắt trừu tượng

Diễn đạt lại, rút gọn hoặc tổng hợp lại ý chính từ văn bản cần tóm tắt.

- Ưu: Cho bản tóm tắt tự nhiên, mạch lạc và diễn giải ý nghĩa sâu hơn.
- Nhược: Yêu cầu dữ liệu huấn luyện lớn, mô hình ngôn ngữ phức tạp, có thể sai lệch nếu hiểu sai nội dung.

GIỚI THIỆU BÀI TOÁN

Các mô hình sử dụng

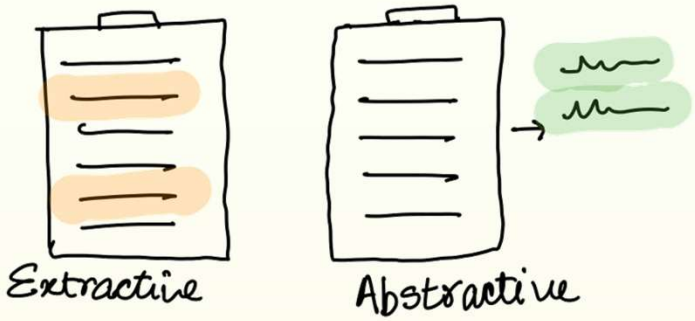

Extractive summarization

Tóm tắt trích xuất

- PhoBERT + Kmeans/ DBSCAN (unsupervise)
- PhoBERT + Linear Layer

Abstractive summarization

Tóm tắt trừu tượng

- ViT5
  - Zero-shot
  - Fine-tuning
- LLaMA
  - Zero-shot
  - Fine-tuning

CƠ SỞ LÝ THUYẾT

Kiến trúc Transformer

Mô hình nền tảng trong lĩnh vực NLP với kiến trúc Seq2seq dựa theo cơ chế attention cho phép mô hình hiểu được ngữ cảnh văn bản đầu vào và sinh ra văn bản mới.

Thành phần chính:

- Input embedding
- Postitional encoding
- Multi-Head Attention
- Masked Multi-Head Attention
- Feedforward
- LayerNorm

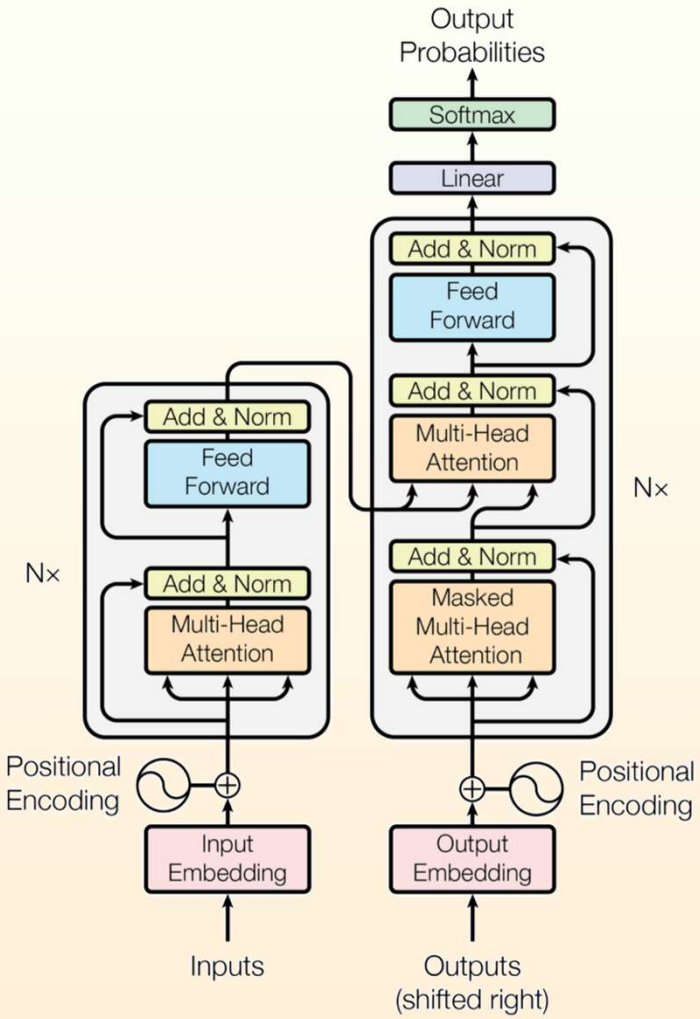

Figure 1: The Transformer - model architecture.

CƠ SỞ LÝ THUYẾT

Mô hình BERT

BERT là mô hình do Google phát triển dựa trên kiến trúc Transformer, nhưng được thiết kế đặc biệt bằng cách lược bỏ hoàn toàn phần Decoder để tập trung tận dụng khối Encoder. Thông qua cơ chế Self-Attention, BERT có khả năng thấu hiểu ngữ cảnh và cấu trúc ngữ nghĩa của văn bản theo hai chiều đồng thời, tạo nên hiệu suất vượt trội trong cac tác vụ trong xử lý ngôn ngữ tự nhiên.

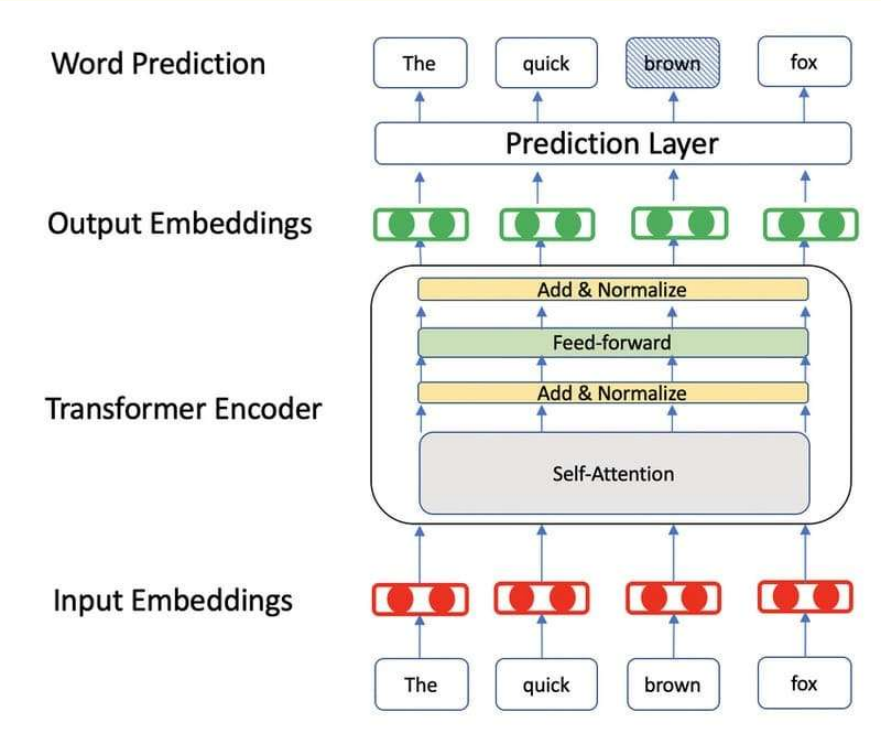

Các bước xử lý trong cơ chế hoạt động của mô hình BERT

CƠ SỞ LÝ THUYẾT

Mô hình ViT5

- Kế thừa T5 & Tối ưu Tiếng Việt: Là phiên bản dựa trên mô hình T5 của Google, được huấn luyện chuyên sâu trên tập dữ liệu Tiếng Việt quy mô lớn để xử lý tốt ngôn ngữ tự nhiên tiếng Việt.
- Kiến trúc Sequence-to-Sequence: Sử dụng cấu trúc Encoder-Decoder hoạt động theo cơ chế hai chiều (bidirectional), giúp mô hình bao quát toàn bộ ngữ cảnh câu đầu vào trước khi xử lý.
- Ứng dụng: Ứng dụng trong NLP bằng cách đưa mọi bài toán về dạng text-to-text như : Tóm tắt văn bản , dịch thuật, trả lời câu hỏi, ...

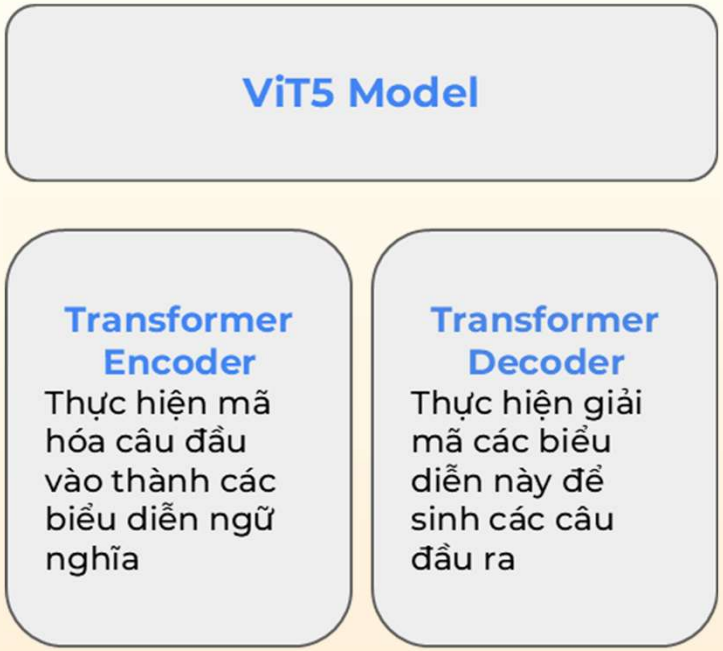

Kiến trúc tổng quan của mô hình ViT5 với hai khối encode và decode

CƠ SỞ LÝ THUYẾT

Mô hình Llama 3.2

- Kiến trúc: Sử dụng Transformer thuần Decoder , loại bỏ hoàn toàn Encoder để tối ưu hóa cho tác vụ sinh văn bản.
- Mã hóa vị trí: Ứng dụng RoPE (Rotary Positional Embeddings) thay thế lớp embedding vị trí truyền thống, giúp mô hình xử lý tốt hơn mối quan hệ giữa các từ ở khoảng cách xa.
- Quy mô: Mô hình chứa khoảng 1 tỷ tham số, hỗ trợ cửa sổ ngữ cảnh mở rộng lên tới 128k token

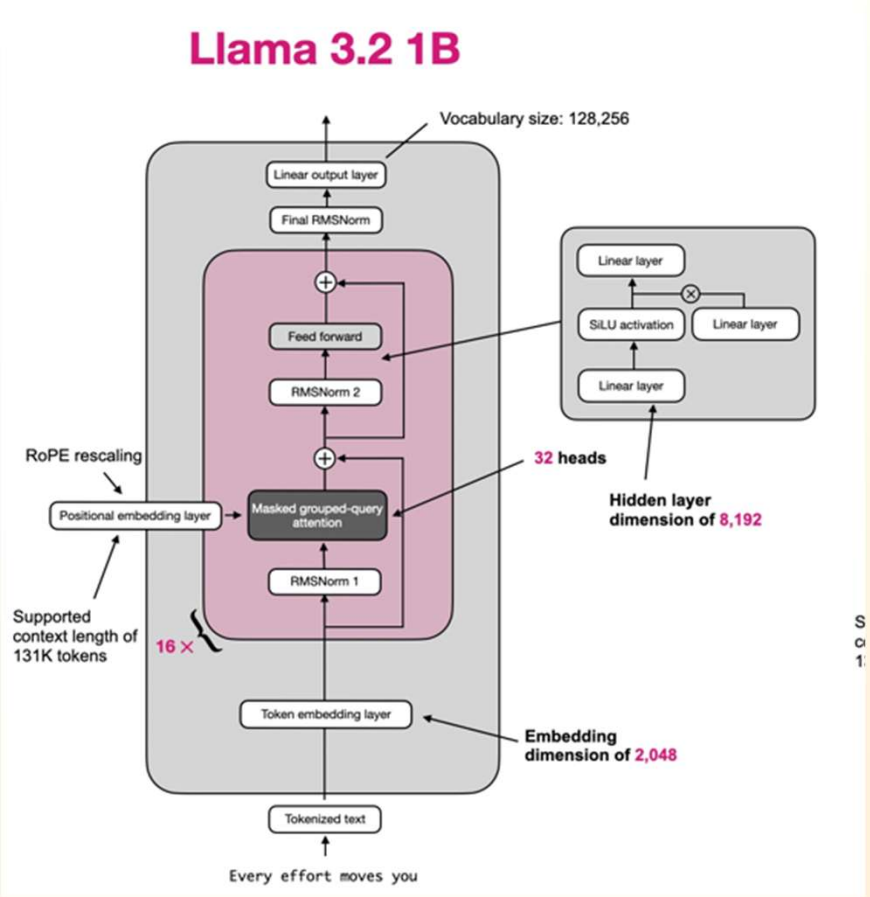

Kiến trúc mô hình Llama 3.2

CƠ SỞ LÝ THUYẾT

Kỹ thuật finetune QLoRA

- Định nghĩa: Kỹ thuật kết hợp phương pháp LoRA với lượng tử hóa để nén trọng số mô hình từ độ chính xác cao xuống thấp hơn, giúp tối ưu bộ nhớ và tốc độ tính toán mà vẫn đảm bảo hiệu năng nhờ quá trình giải lượng tử hóa khi xử lý.

- LoRA: kĩ thuật fine-tuning tham số tối ưu cho các mô hình ngôn ngữ lớn, tiết kiệm tài nguyên và thời gian bằng cách chỉ cập nhật một lượng nhỏ tham số thông qua cấu trúc ma trận hạng thấp mà vẫn duy trì hiệu năng cao và khả năng thích ứng với các tác vụ mới.

CƠ SỞ LÝ THUYẾT

Kỹ thuật finetune QLoRA

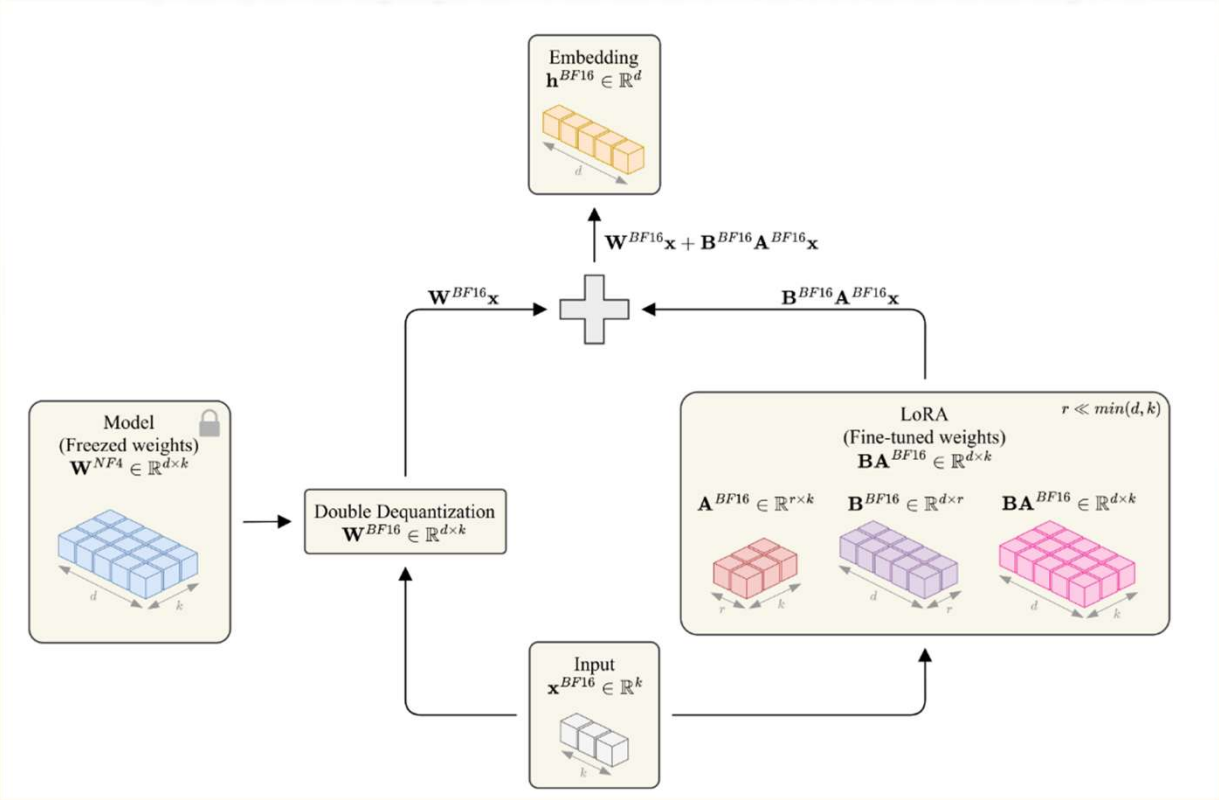

CHỈ SỐ ĐÁNH GIÁ CHẤT LƯỢNG MÔ HÌNH

ROUGE – Recall-Oriented Understudy for Gisting Evaluation

Là chỉ số đánh giá mức độ trùng lặp n-gram giữa tóm tắt mô hình sinh ra và bản tóm tắt tham chiếu.

Ưu tiên đánh giá xem mô hình có bao phủ hết các cụm từ quan trọng xuất hiện trong tóm tắt chuẩn hay không.

CHỈ SỐ ĐÁNH GIÁ CHẤT LƯỢNG MÔ HÌNH

ROUGE – Recall-Oriented Understudy for Gisting Evaluation

C: Tóm tắt mô hình sinh

R: Tóm tắt tham chiếu

$G_n(C)$: Tập n-gram trong C

$G_n(\mathrm{R})$: Tập n-gram trong R

$\mathrm{Count}(\mathrm{g}, \mathrm{S})$: Số lần n-gram xuất hiện trong câu S

Số n-gram trùng nhau

$$\mathrm{Overlap}_n = \sum_{g \in G_n(C) \cap G_n(R)} \min\big(\mathrm{Count}(g, C), \mathrm{Count}(g, R)\big)$$

Số n-gram mỗi bên

$$\mathrm{Total}_n^{(C)} = \sum_{g \in G_n(C)} \mathrm{Count}(g, C))$$

$$\mathrm{Total}_n^{(R)} = \sum_{g \in G_n(R)} \mathrm{Count}(g, R))$$

CHỈ SỐ ĐÁNH GIÁ CHẤT LƯỢNG MÔ HÌNH

ROUGE – Recall-Oriented Understudy for Gisting Evaluation

Số n-gram trùng nhau

$$\text{Overlap}_n = \sum_{g \in G_n(C) \cap G_n(R)} \min\big(\text{Count}(g, C), \text{Count}(g, R)\big)$$

Số n-gram mỗi bên

$$\text{Total}_n^{(C)} = \sum_{g \in G_n(C)} \text{Count}(g, C))$$

$$\text{Total}_n^{(R)} = \sum_{g \in G_n(R)} \text{Count}(g, R))$$

Precision, Recall, F1 cho ROUGE-N

$$P_{\text{ROUGE}-n} = \frac{\text{Overlap}_n}{\text{Total}_n^{(C)}}$$

$$R_{\text{ROUGE}-n} = \frac{\text{Overlap}_n}{\text{Total}_n^{(R)}}$$

$$F1_{\text{ROUGE}-n} = \frac{2 \cdot P_{\text{ROUGE}-n} \cdot R_{\text{ROUGE}-n}}{P_{\text{ROUGE}-n} + R_{\text{ROUGE}-n}}$$

CHỈ SỐ ĐÁNH GIÁ CHẤT LƯỢNG MÔ HÌNH

ROUGE – Recall-Oriented Understudy for Gisting Evaluation

ROUGE-L (Dựa trên LCS)

Giả sử:

- X: Chuỗi từ của tóm tắt tham chiếu, dài m
- Y: Chuỗi từ của tóm tắt tham chiếu, dài n
- LCS(X, Y): Độ dài dãy con chung dài nhất giữa X và X

Precision, Recall dựa trên LCS

- $R_{LCS} = \frac{\mathrm{LCS}(X,Y)}{m}$
- $P_{LCS} = \frac{\mathrm{LCS}(X,Y)}{n}$

F-measure của ROUGE-L với $\beta = 1$

- $F_{\mathrm{ROUGE}-L} = \frac{2 .P_{LCS}R_{LCS}}{P_{LCS}+R_{LCS}}$

CHỈ SỐ ĐÁNH GIÁ CHẤT LƯỢNG MÔ HÌNH

BLEU – Bilingual Evaluation Understudy

- BLEU: So sánh tóm tắt mô hình với tóm tắt tham chiếu bằng n-gram precision và phạt nếu câu mô hình quá ngắn so với câu chuẩn.
- BLEU cao khi mô hình dùng từ hoặc cụm từ giống văn bản chuẩn.

Brevity Penalty:

$$\mathrm{BP} = \begin{cases} 1, & \text{nếu } c > r \\ e^{1-\frac{r}{c}}, & \text{nếu } c \leq r \end{cases}$$

Nếu câu mô hình ngắn hơn câu chuẩn thì r/c lớn, BP nhỏ.

Nếu câu mô hình dài hơn hoặc tương đương, BP = 1 (không phạt)

CHỈ SỐ ĐÁNH GIÁ CHẤT LƯỢNG MÔ HÌNH

BLEU – Bilingual Evaluation Understudy

Brevity Penalty:

$$\mathrm{BP} = \begin{cases} 1, & \text{nếu } c > r \\ e^{1-\frac{r}{c}}, & \text{nếu } c \leq r \end{cases}$$

Nếu câu mô hình ngắn hơn câu chuẩn thì r/c lớn, BP nhỏ.

Nếu câu mô hình dài hơn hoặc tương đương, BP = 1 (không phạt)

BLEU Score

$$\mathrm{BLEU} = \mathrm{BP} \cdot \exp\left(\sum_{n=1}^{N} w_n \log p_n\right)$$

Thường $w_n = \frac{1}{N}$

TRIỂN KHAI

Chuẩn bị dữ liệu

- 29509 mẫu huấn luyện (Extractive)
- 29509 mẫu huấn luyện (Abstractive)
- 5000 mẫu dữ liệu benchmark

Xử lý dữ liệu

Extractive

- PhoBERT + Kmeans / DBSCAN
- PhoBERT + Linear Layer

Abstractive

- ViT5
- Llama 3.2

Đánh giá

TRIỂN KHAI

OREO – Estimating Oracle Expectation

Algorithm 1 Labeling with Oracle Expectation

```
function OREO(n, k, p)
    ▷ Max number of sentences in a summary, beam size, and oracle distribution
    Initialize beam B
    for j ← n do
        B ← STEP(j, B)
    Initialize ℓ'_i to 0, ∀i    ▷ Pre-scaled expectation
    for b, r ← B do
        for x ← b do
            ℓ'_i ← r + ℓ' * p_i
    ℓ = MAXMINSCALE(ℓ')
    return ℓ
end function
```

```
function STEP(j, B)    ▷ Step and beam
    Initialize visited paths V
    for b, v ← B do
        if |b| < j then
            continue    ▷ Skip early stopping
        for i ← |D| do
            b' = SORT(b + {i})
            if b' not in V then
                v' = ROUGE(b')
                if v' > v then
                    B ← B + {(b', v')}
            V ← V + {b'}
    return TOP-k(B)    ▷ Pruned beam
end function
```

Mô hình	ROUGE-1	ROUGE-2	ROUGE-L	BLEU
PhoBERT + KMeans	0.67	0.42	0.44	23
PhoBERT + DBSCAN	0.49	0.30	0.34	9
PhoBERT + Linear layer	0.69	0.51	0.50	29.83
ViT5 (none fine-tune)	0.37	0.22	0.27	1.527
ViT5 (fine-tune)	0.71	0.49	0.50	30.11
Llama 3.2 (None finetune)	0.61	0.43	0.43	24.15
Llama 3.2 (Fine tune)	0.70	0.51	0.52	35

Chúng em cảm ơn cô và các bạn đã lắng nghe